

Міністерство освіти і науки України
Національний університет “Львівська політехніка”
Інститут прикладної математики та фундаментальних наук
Кафедра прикладної математики

ЗВІТ
про виконання лабораторної роботи №5
з курсу «Математична Статистика»

Виконав:
Студент групи ПМ-33
Маркевич Леонід
Прийняв:
Янішевський В.С.

Львів 2023

Лабораторна робота 5

Варіант 12

ТЕМА: Побудова лінійної багатофакторної моделі та дослідження її на адекватність.

МЕТА: засвоїти основні формули і вирази багатофакторної регресії та вміти застосовувати їх до практичних задач. За даними спостережень визначити лінійну багатофакторну регресію, навести оцінки.

ЗАВДАННЯ:

1. За даними таблиці здійснити якісний аналіз залежності між факторами.
2. Побудувати регресійну модель вигляду
$$y=b_0+b_1 x_1+b_2 x_2.$$
3. Перевірити модель на адекватність за F – критерієм Фішера.
4. Провести оцінку значимості параметрів рівняння регресії b_1 , b_2 та визначити інтервали довіри для них.
5. Знайти довірчий інтервал для окремого значення залежної змінної.
6. Навести тлумачення параметрів b_0 , b_1 , b_2 .
7. Навести висновки і оформити звіт роботи.

ХІД РОБОТИ:

Реалізація виконана на мові програмування *Python* з використанням бібліотек *numpy*, *pandas*, *statsmodels*, *random*, *matplotlib*, *scipy*.

1. За даними таблиці здійснити якісний аналіз залежності між факторами.

Програмна реалізація:

```
data = pd.read_csv('lab5/data.csv')

y = calc_data(1.5, data['y'])
x1 = calc_data(2.5, data['x1'])
x2 = calc_data(10, data['x2'])

X = np.column_stack((np.ones(len(x1)), x1, x2))
B = find_params(y, X)
U = find_param_u(y, X, B)
depend_analysis(data)
```

```

def calc_data(a, i):
    N = random.uniform(0, 1)
    data = i + a * (N - 1/2)
    return data

def find_params(y, X):
    B = np.linalg.inv(X.T @ X) @ (X.T @ y)
    print('B: ', B)
    return B

def find_param_u(y, X, B):
    y_hat = X @ B
    residuals = y - y_hat
    print('Залишки: ', residuals)
    return residuals

def depend_analysis(data):
    correlation_matrix = data.corr()
    print("\nКореляційна матриця:")
    print(correlation_matrix)

```

Приклад роботи:

y: 0	12.218862	x1: 0	4.344042	x2: 0	121.886858
1	16.118862	1	8.744042	1	171.886858
2	18.718862	2	10.344042	2	221.886858
3	15.718862	3	7.744042	3	171.886858
4	10.718862	4	3.644042	4	101.886858
5	15.818862	5	8.144042	5	181.886858
6	16.718862	6	8.944042	6	181.886858
7	16.218862	7	8.644042	7	191.886858
8	14.718862	8	6.244042	8	151.886858
9	15.118862	9	7.644042	9	171.886858
10	12.418862	10	4.544042	10	111.886858
11	18.318862	11	9.944042	11	201.886858
12	12.818862	12	5.644042	12	141.886858
13	14.618862	13	6.144042	13	161.886858
14	19.918862	14	11.044042	14	261.886858
15	20.518862	15	11.244042	15	291.886858
16	15.218862	16	8.044042	16	151.886858
17	16.118862	17	7.644042	17	191.886858

```

В: [6.32602343 0.71711181 0.02158093]
Залишки: 0      0.147243
1      -0.187095
2       0.186480
3       0.130017
4      -0.419160
5      -0.272637
6       0.053674
7      -0.447002
8       0.637303
9      -0.398272
10      0.419630
11      0.504943
12     -0.616620
13      0.393205
14      0.021265
15     -0.169586
16     -0.153498
17      0.170110

```

Кореляційна матриця:

	y	x1	x2
y	1.000000	0.979313	0.962905
x1	0.979313	1.000000	0.925229
x2	0.962905	0.925229	1.000000

2. Побудувати регресійну модель вигляду

$$y = b_0 + b_1 x_1 + b_2 x_2.$$

Програмна реалізація:

```

model = build_regresive_model(x1, x2, y, B)

def build_regresive_model(x1, x2, y, B):
    X = sm.add_constant(pd.DataFrame({'x1': x1, 'x2': x2}))
    model = sm.OLS(y, X).fit()
    print('\n', model.summary())
    print("\nРегресійна модель:", f"\ny = {B[0]} + {B[1]} * x1 + {B[2]} * x2")
    return model

```

Приклад роботи:

OLS Regression Results						
Dep. Variable:	y	R-squared:	0.981			
Model:	OLS	Adj. R-squared:	0.979			
Method:	Least Squares	F-statistic:	397.4			
Date:	Thu, 09 Nov 2023	Prob (F-statistic):	1.02e-13			
Time:	11:56:38	Log-Likelihood:	-6.5144			
No. Observations:	18	AIC:	19.03			
Df Residuals:	15	BIC:	21.70			
Df Model:	2					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
const	6.3260	0.352	17.995	0.000	5.577	7.075
x1	0.7171	0.108	6.631	0.000	0.487	0.948
x2	0.0216	0.005	4.262	0.001	0.011	0.032
Omnibus:	0.856	Durbin-Watson:	2.952			
Prob(Omnibus):	0.652	Jarque-Bera (JB):	0.696			
Skew:	0.057	Prob(JB):	0.706			
Kurtosis:	2.044	Cond. No.	718.			
Регресійна модель:						
y = 6.326023427021678 + 0.7171118144838624 * x1 + 0.021580926355914715 * x2						

3. Перевірити модель на адекватність за F – критерієм Фішера.

Програмна реалізація:

```
check_Fisher(calculate_F_value(X, y, B, U))

def calculate_F_value(X, Y, B, U):
    n = len(Y)
    m = len(B)

    Y_hat = X @ B
    SSR = ((Y_hat - Y.mean()) ** 2).sum()
    SSE = (U ** 2).sum()
    MSR = SSR / (m - 1)
    MSE = SSE / (n - m)
    F_value = MSR / MSE

    print('\nF-value: ', F_value)
    return F_value

def check_Fisher(F_value):
    alpha = 0.05
```

```

if F_value < alpha:
    print("Модель є адекватною за F-критерієм Фішера")
else:
    print("Модель не є адекватною за F-критерієм Фішера")

```

Приклад роботи:

```

F-value: 397.425295244778
Модель не є адекватною за F-критерієм Фішера

```

4. Провести оцінку значимості параметрів рівняння регресії b_1 , b_2 та визначити інтервали довіри для них.

Програмна реалізація:

```

evaluate_significance(y, X, B, U)

def evaluate_significance(y, X, B, U):
    degrees_of_freedom = len(y) - X.shape[1]
    mse = np.sum(U**2) / degrees_of_freedom
    var_B = mse * np.linalg.inv(X.T @ X)

    se_B = np.sqrt(np.diag(var_B))
    print('Стандартні помилки: ', se_B)

    t_stats = B / se_B
    print('t-статистика: ', t_stats)

    p_values = [2 * (1 - stats.t.cdf(np.abs(t), degrees_of_freedom))
    for t in t_stats]
    print('p-значення: ', p_values)

    confidence_interval = [stats.t.interval(0.95, degrees_of_freedom,
    loc=b, scale=se) for b, se in zip(B, se_B)]
    print('Інтервали довіри: ', confidence_interval)

```

Приклад роботи:

```

Стандартні помилки: [0.35153634 0.10814681 0.00506409]
t-статистика: [17.99536124  6.63091047  4.26155914]
p-значення: [1.4491297051222318e-11, 7.999216658172159e-06, 0.0006826404978952372]
Інтервали довіри: [(5.576741454857739, 7.075305399185387), (0.48660234540367553, 0.9476212835640004), (0.010787070363601037, 0.03237478234825655)]

```

5. Знайти довірчий інтервал для окремого значення залежної змінної.

Програмна реалізація:

```
def predict_confidence_interval(x_new, X, y, B, U, confidence=0.95): 1 usage
    y_hat = x_new @ B
    degrees_of_freedom = len(y) - len(B)
    mse = np.sum(U**2) / degrees_of_freedom
    se = np.sqrt(mse * (1 + x_new @ np.linalg.inv(X.T @ X) @ x_new.T))
    t_value = stats.t.ppf((1 + confidence) / 2, degrees_of_freedom)
    confidence_interval = (y_hat - t_value * se, y_hat + t_value * se)

    return confidence_interval
```

Приклад роботи:

Довірчий інтервал для прогнозованого значення у: (31.56574423486063, 54.09233964892202)

6. Навести тлумачення параметрів b_0 , b_1 , b_2 .

У контексті лінійної регресії, параметри b_0 , b_1 , b_2 мають наступне тлумачення:

b_0 - це інтерсепт або вільний член регресійного рівняння. Це значення y , коли всі незалежні змінні x_1 , x_2 , ... дорівнюють нулю. Іншими словами, це очікуване значення залежної змінної, якщо всі незалежні змінні відсутні або не мають впливу.

b_1 - це коефіцієнт нахилу для незалежної змінної x_1 . Він показує, на скільки зміниться очікуване значення залежної змінної y , якщо x_1 збільшиться на одиницю, при умові, що всі інші незалежні змінні залишаються незмінними. Це можна розглядати як "вагу" або "вплив" змінної x_1 на y .

b_2 - це коефіцієнт нахилу для незалежної змінної x_2 . Аналогічно до b_1 , він показує зміну в очікуваному значенні y при збільшенні x_2 на одиницю, при незмінних інших змінних.

ВИСНОВОК:

У цьому дослідженні розглянув створення та оцінку адекватності лінійної моделі, яка враховує кілька факторів. Методом візуального аналізу та оцінки кореляції між залежною змінною та факторами сконструював лінійну регресію за допомогою методу найменших квадратів.

Перевірів адекватність моделі, використовуючи F-критерій Фішера, та оцінив значущість регресійних коефіцієнтів b_1 і b_2 , встановивши для них інтервали довіри. Крім того, було визначено довірчий інтервал для окремих прогнозованих значень залежної змінної і проаналізовано значення параметрів моделі.

Це дослідження надало цінні відомості про взаємодію між факторами та залежною змінною, що зробило дану модель корисною для подальшого аналізу та прогнозування.